队伍编号	MCB2606971
赛道	A

啤酒风味评分、关键化合物识别与风格生成

摘　要

啤酒风味由化学组成决定，但化合物谱到感官评分的映射多变量、非线性，附件数据又存在高维、缺失与标签不可观测三重困难。本文以 250 个样品的 231 个化合物特征、50 个感官维度与 22 个风格标签为基础，按**“基线—改进—最终”**逐层建模。

针对问题一，评分卡为空白，本文把任务拆为连续潜变量回归与有序校准两层：逐维均值与岭回归基线的宏平均 R^2 为 -0.029 与 **0.162**，加入缺失指示与风格先验后升至 **0.186**；最终用五类基学习器折外等权融合并做保序校准，5 折 $\times$ 3 次重复下取得 $R^2 = 0.227$、**Spearman 0.432**、**QWK 0.376**。酸度与酒精度（0.690/0.678）最易预测，阈值型缺陷维度接近 0；随机遮蔽 30% 时 R^2 仅相对下降 **19.3%**。

针对问题二，本文由化合物相关矩阵构建共表达图，每个节点保留 10 个强相关邻居，得到 231 个节点、1 683 条边、8 个社区，模块度 **0.586**；社区与化学家族基本对齐——酒花萜类（C2、C8）、酵母酯类与醇类（C4、C6）、麦芽醛与呋喃（C5）各自成模块。排序层以边际相关为基线，补充弹性网、极端随机树、LightGBM 的 SHAP 值与网络拉普拉斯平滑，再做 **Borda 秩融合**得到每个感官维度的 Top-3。500 次 bootstrap 下平均入选频率 **0.525**、方法间 Jaccard 系数 **0.313**，说明单条目比整组更稳定。双乙酰、DMS 与反式-2-壬烯醛的纯数据 Top-3 均未选中同名化合物（融合名次 **120.8**、**86.5**、**91.4**），本文另给机制导向名单，代价是与纯数据重合率降至 **0.387**；而苦味（异 α 酸）、4VG（挥发性酚）与酒花柑橘香（萜醇）三条链条两栏一致。

针对问题三，本文把 70 个校准化合物变换到正态分数空间，用**条件高斯 copula** 学习各风格分布，以 Ledoit–Wolf 收缩协方差控制小样本风格；迁移用**高斯最优传输**的闭式映射，并以“严格阈值与风格 75% 分位数的较大者”作为缺陷上限。三风格平均的 **MMD 为 0.038**、**覆盖度 0.863**、**风格命中率 0.981**，优于均值加噪声（0.063/0.300/0.851）与全局协方差（0.066/0.233/0.667）；Pils/Lager 迁移为 Tripel 后命中率**由 0.00 升至 0.91**，严格投影下 DMS、双乙酰与反式-2-壬烯醛不恶化，相对风格上限的超标率为 0；Tripel、Kriek、Lambic 的生成画像与真实画像的 Pearson 相关为 **0.968**、**0.957**、**0.990**。

关键词：啤酒风味；缺失数据；多任务回归；共表达网络；稳定性选择；条件生成模型

目录

1 问题重述 **1**

1.1 问题背景 1

1.2 数据说明 1

1.3 问题提出 2

1.4 技术路线 2

2 数据预处理 **3**

2.1 符号说明 3

2.2 数据概况与表间对齐 3

2.3 变量变换核验 4

2.4 缺失值与异常值处理 5

2.5 标准化与特征构造 5

2.6 外部数据 6

3 问题一：数据缺失条件下的感官评分 **6**

3.1 问题分析 6

3.2 评价指标 7

3.3 模型构建：从基线到折外融合 8

3.3.1 基线模型：逐维均值与岭回归 8

3.3.2 改进模型：缺失指示与风格先验 8

3.3.3 最终模型：五模型折外等权融合 9

3.3.4 分级校准：由感官潜变量到 0–6 分 9

3.4 实验设置 10

3.5 结果与分析 11

3.6 讨论 12

4 问题二：化合物——风味关联分析 **13**

4.1 问题分析 13

4.2 评价指标 13

4.3 模型构建：从共表达图到秩融合 14

4.3.1 共表达图的构建与社区结构 14

4.3.2 基线方法：边际相关排序 15
4.3.3 改进方法：共表达图上的拉普拉斯平滑 16
4.3.4 最终方法：五方法秩融合与稳定性选择 16
4.4 实验设置 17
4.5 结果与分析 17
4.6 稳定性与化学合理性论证 18
4.6.1 纯数据结果与机制导向结果的分工 18
4.6.2 化学合理性核对 19
4.7 讨论 20

5 问题三：“风味指纹”与风格条件生成 20
5.1 问题分析 20
5.2 风味指纹与评价指标 21
5.3 模型构建：从风格均值到缺陷约束 22
5.3.1 基线方法：风格均值与全局协方差采样 22
5.3.2 改进方法：条件高斯 copula 22
5.3.3 最终方法：风格感知的缺陷约束 23
5.4 跨风格迁移：最优传输与边际校准 24
5.5 实验设置 25
5.6 结果与分析 25
5.7 讨论 26

6 结论与建议 27
6.1 主要结论 27
6.1.1 问题一 27
6.1.2 问题二 28
6.1.3 问题三 28
6.2 对酿造实践的建议 29
6.3 局限与展望 29

1 问题重述

1.1 问题背景

啤酒的风味、香气与口感由其化学组成决定[1]。酵母在糖代谢中生成乙醇与二氧化碳，并通过酯化反应和氨基酸的 Ehrlich 降解生成酯类与高级醇；酒花添加带来萜烯、萜醇与异 α 酸[2]；麦芽提供美拉德产物与醛类；非酿酒酵母与细菌则可能产生双乙酰、4-乙烯基愈创木酚、二甲基硫（DMS）等缺陷物质[3]。同一种化合物在不同浓度区间对感官的贡献方向可能相反，多种化合物之间又存在共同代谢与共表达关系，因此“化合物谱—感官画像”是一个多变量、非线性的映射问题，仅靠单变量相关分析难以刻画其整体结构。

附件给出了 250 个商用啤酒样品的化合物丰度、化合物相关矩阵、感官评分卡与感官描述数据。这些数据同时覆盖化学测量、感官评价与文本描述三个层面，但并非为同一建模任务整理：化合物列的量纲与变换方式并不统一，感官表只提供标准化后的连续值，跨表主键还存在格式问题。上述特征决定了本文必须先统一数据口径，再针对三问分别建模。

1.2 数据说明

8 份附件数据的内容、规模与本文用途见表 1.1。

表 1.1 附件数据一览与本文用途

文件	主要内容	规模	本文用途
`1.csv`	250 个啤酒样品的化合物丰度矩阵	250×234	问题一至三的主特征
`2.csv`	化合物之间的相关系数矩阵	231×231	问题二共表达图边权
`3.xlsx`	Aroma 与 Flavour 两套评分卡	13 个 sheet	问题一的维度定义
`4.csv`	感官评分的标准化连续值	250×53	问题一、二监督信号
`5.csv`	感官属性之间的相关矩阵	50×50	感官维度结构分析
`6.csv`	化合物与感官属性的交叉相关矩阵	44×50	问题二一致性校验
`7.csv`	感官描述符与风格标签	250×189	问题三的风格标签
`8.xlsx`	感官阈值、校准化学数据与价格等	7 个 sheet	阈值与变换核验

题面描述与附件实测存在一些出入，本文以附件实测为准：

（1） 题面称 226 种啤酒，`1.csv` 实为 250 个样品；

（2） 题面称 `3.xlsx` 含 10 个评分卡，实为 beer_1 至 beer_12 共 12 个 sheet 加 1 个 summary，且均为空白评分卡，不含已填写的分数；

（3） 题面称两套感官维度共约 40 个，实测每套 15 个、共 30 个，`4.csv` 另含 20 个 taste/palate/overall 维度，合计 50 个；

（4） 题面称 `6.csv` 为 46×50，实测 44 个指标与 50 个感官属性；

（5） 题面称 `7.csv` 为 250×187，实测 189 列。

其中后三条直接影响建模：可用的感官维度数、参与交叉相关的指标数、以及风格标签所在的列，都与题面口径不同。此外，`4.csv` 与 `7.csv` 的 `beer_id` 有 213/250 行存为科学计数法、仅 96 个唯一值，不能作连接键；本文一律用取值 1–250 且唯一的 `beer` 列连接，详见第 2 章。

1.3 问题提出

（1） **问题一：数据缺失条件下的感官评分。**以 `1.csv` 的化合物数据为基础，给出 `3.xlsx` 定义的 Aroma 与 Flavour 两套、共 30 个感官维度的 0–6 分分级评分。困难在于评分卡是空白的、没有可直接监督的等级标签，化合物维度 231 与样本数 250 同量级且存在 73 个缺失单元。

（2） **问题二：化合物—风味分析。**以 `2.csv` 构建化合物共表达图，结合 `1.csv` 的特征给出每个感官维度的 Top-3 关键因素化合物，并论证其稳定性与化学合理性。困难在于化合物强共线，单个化合物的重要性会被相关化合物“分摊”，边际相关排序在重采样下不稳，且相关关系不等于因果关系。

（3） **问题三：风味与“风味指纹”生成。**以 `tasting_category_fine` 为风格标签学习条件生成模型，在给定风格（如 Tripel、Kriek、Lambic）下生成化合物谱与感官画像，并完成 Pils/Lager 到 Tripel 的跨风格迁移，同时保证 DMS、双乙酰、4VG、反式-2-壬烯醛与 stale hops 等缺陷化合物不恶化。困难在于 22 个风格样本量悬殊（最多 31 个、最少 3 个），逐风格建模易过拟合，且生成结果没有唯一真值。

1.4 技术路线

三问共享同一套数据底座与符号体系（第 2 章），先给出可复现的简单基线，再针对基线的具体缺陷逐层改进，最后用同一数据划分上的对比说明每一层改进是否必要。问题一解决“化合物到感官”的有监督映射；问题二给出该映射中少数关键化合物及其稳定性，为问题一的结果提供了可解释性检查；问题三反过来由风格标签生成化合物谱，

并用问题一的模型为生成结果提供感官解释。三个问题可以相互校验，而不是三个彼此独立的模型。

整篇文章布局安排如下：第 2 章给出数据对齐、缺失处理、变换核验与符号约定；第 3 章至第 5 章分别回答问题一至问题三；第 6 章总结结论，并给出建议与局限。

2 数据预处理

2.1 符号说明

本文定义了如下使用次数较多的符号，其余符号在使用时注明。

表 2.1 主要符号及含义

符号	含义	维度/取值
N, P, S, G	样本数、化合物数、感官维度数、风格类别数	—
i, j, s, g	样本、化合物、感官维度、风格索引	$i = 1, \ldots, N$
$\boldsymbol{x}_i$，$\boldsymbol{X}$	第 i 个样本的化合物特征向量、特征矩阵	$\mathbb{R}^P$，$\mathbb{R}^{N\times P}$
$y_{i,s}$，$\boldsymbol{Y}$	第 i 个样本第 s 维的评分、评分矩阵	$\mathbb{R}$，$\mathbb{R}^{N\times S}$
z_i	第 i 个样本的风格标签	$\{1, \ldots, G\}$
$r_{j,j'}$，$\boldsymbol{R}$	化合物 j 与 j' 的相关系数、相关矩阵	$[-1, 1]$，$\mathbb{R}^{P\times P}$
$\boldsymbol{A}$	共表达图的邻接矩阵	$\{0, 1\}^{P\times P}$
$\boldsymbol{\beta}_s$，$\boldsymbol{B}$	第 s 维的回归系数、系数矩阵	$\mathbb{R}^P$，$\mathbb{R}^{P\times S}$
$w_{j,s}$	化合物 j 对感官维度 s 的重要性	$\mathbb{R}$
$\hat{y}_{i,s}$	第 i 个样本第 s 维的模型预测	$\mathbb{R}$

2.2 数据概况与表间对齐

附件各表的样本标识并不一致。`1.csv`、`4.csv` 与 `7.csv` 都含有 `beer` 列，取值为 1–250 的唯一编号；而 `beer_id` 在 `4.csv` 与 `7.csv` 中有 213/250 行被存成科学计数法，仅余 96 个唯一值，无法作为主键。本文因此以 `beer` 为唯一连接键建立样本主表，再逐表左连接，连接后核对各列的非空数量与取值范围。

主表为 250 行、231 个化合物特征。自然缺失共 73 个单元（占 0.12%），集中在 `amyl_acetate`（27）、`aroma_hops_sum`（13）、`methylpyrazine`（12）、`2,3-butanedione`（9）与 `3-methylbutanal`（7），并非均匀散布。`1.csv` 的 231 个特征列与 `2.csv` 的行列

顺序逐位对应，这一对应关系既是两表可用的前提，也作为读取时的一致性断言。

感官目标共 50 维。各维标准化后的标准差在 0.37–0.86 之间，目标两两相关的中位数仅 0.016，但存在少量强相关对（最高 $r = 0.98$）。这说明 50 个维度既不能当作完全独立的任务，也不宜整体视为一个低秩问题，问题一对这两种设定都做了对照。

风格标签共 22 类，样本量高度不均衡：最多的 `Blond` 31 个、`Tripel` 28 个，最少的 `Faro` 仅 3 个。小样本风格在问题三中改用收缩估计，并单独报告其不确定性。

2.3 变量变换核验

`1.csv` 的化合物列并非统一变换。以 `8.xlsx` 的 Calibrated chemical dataset 为参照，对 70 个可校准列逐列比较校准浓度与 $10^{x_{i,j}}$、$x_{i,j}$ 的关系：37 列满足 calibrated $= 10^x$ 的 log10 关系，33 列满足 calibrated $\approx x$ 的线性关系，两类的中位比值分别在 1 附近。其余 161 列没有对应的校准浓度，按含负值或值域小于 12 判定为 log10。据此建立逐列变换表，还原关系为

$$x_{i,j}^{cal} = \begin{cases} 10^{x_{i,j}}, & j \in \mathcal{J}_{\log}, \\ x_{i,j}, & j \in \mathcal{J}_{\lin}, \end{cases} \tag{2.1}$$

其中 $\mathcal{J}_{\log}$ 为 37 个 log10 列与 161 个推断 log10 列的并集，$\mathcal{J}_{\lin}$ 为 33 个线性列。核对结果见表 2.2。

表 2.2 `1.csv` 逐列变换的核对结果

类型	列数	判定依据	典型列
校准 log10	37	calibrated $= 10^x$	`ethyl_acetate`、`DMS`、`pH`
校准线性	33	calibrated $\approx x$	`linalool`、`geraniol`、`2,3-butanedione`
推断 log10	161	含负值或值域小于 12	`X4VG`、萜类、酯类

本次的建模不使用还原后的浓度，而是直接对逐列变换后的数值做分位数变换。原因有两个：一个是不同化合物的量纲相差数个数量级，直接给浓度会让正则化偏向大尺度的列；另一个是把 10^x 误套到 33 个线性列上会引入系统性的数量级错误，而分位数变换是单调的，不依赖具体变换底数。浓度只在解释具体化合物时按式(2.1) 还原。

关于单位标注，`X.E..2.nonenal` 在附件中标注为 mg/L，但其数值范围（`Pils/Lager` 中位数 0.002、`Tripel` 0.011）与文献常用的 μg/L 阈值处于同一量级，本文按 μg/L 解释；若按标注单位，全部样本都远低于检测限，该维度将失去区分度。这一判断在问题

三的阈值约束中沿用。

2.4 缺失值与异常值处理

记缺失掩码为 $\boldsymbol{M} \in \{0,1\}^{N\times P}$，$m_{i,j}=1$ 表示第 i 个样本第 j 个化合物被观测到；缺失机制对插补的影响按 Little 与 Rubin 的框架处理[4]。处理遵循两条原则。第一，插补、标准化与阈值选择只在训练折内拟合，验证折与测试折只做变换，避免信息泄漏；第二，插补方法作为敏感性分析的一个因素，而不是只保留一种“最优”结果。

基线插补取训练折内逐列中位数，问题一另加缺失指示特征，使模型能区分“浓度低”与“未检测”；问题三对校准浓度中仅有的 3 个负值（`betaglucan.mg.L.` 与 `unfermentables`）截断为 0。

异常值不做统一删除。化合物侧的极端值多对应真实的风味差异，例如特种麦芽带来的高色度、野生菌风格的高挥发酚，删除会连同风格信息一起丢掉。本文改在分位数变换、问题三的 log1p 与稳健区间映射中降低其影响，并在结果中保留极端样本，观察它们是否稳定落在同一风格。

2.5 标准化与特征构造

逐列变换后量纲差异仍然很大，本文在训练集内对各列做标准化

$$\tilde{x}_{i,j}=\frac{x_{i,j}-\mu_j}{\sigma_j}, \tag{2.2}$$

其中 μ_j、σ_j 为训练集第 j 列的均值与标准差。对组成型数据，另做中心对数比变换作为敏感性分析，以检查结论是否依赖单一变换。

特征构造以可解释为先。主特征保留 231 个原始化合物列；按 `8.xlsx` 的 Sensory names 与化合物来源，把化合物归入酒花萜类、酵母酯类、高级醇类、醛酮类、麦芽来源与其他六组，构造组内均值与总和；DMS、双乙酰、4VG 与反式-2-壬烯醛四项缺陷化合物单独成组，供问题三的阈值约束与问题二的合理性解释使用。这里没有做 PCA 或自编码器降维：231 维相对于 250 个样本确实偏高，但降维后的成分不再对应任何具体化合物，与问题二、问题三需要指名化合物的要求相冲突，而正则化与低秩约束已经能承担控制方差的作用。

2.6 外部数据

题目给出的 Kaggle Top Beer Information 数据集[5] 已经实际下载并核对：主表 5,558 行、21 列，内容为 BeerAdvocate 评论的词频统计，许可为 CC BY 4.0。

该数据不能与附件逐酒合并。附件 250 款酒在全部表格中都没有酒名、酒厂或条码，Kaggle 一侧也没有条码；退而用同风格且 ABV 相差 0.3 以内作代理匹配，每款附件酒的候选数中位数为 16、最多 407，且有 9 款无候选，匹配结果没有办法确认到具体酒款。

所以本文只在风格层级使用该数据：把 Kaggle 的 112 个风格按语义归并到附件的 22 个风格，96 个映射成功，覆盖 4,760/5,558 行（85.6%），据此构建 22×11 的风格感官原型。用途有三个：为问题一提供风格级先验，为问题三提供风格原型与迁移方向，和用于风格级的外部校验——风格级 ABV 与附件风格均值的相关为 0.855，而 IBU 仅为 0.449，所以不把 IBU 作为协变量。

上述相关都建立在 22 个风格上，属于生态相关，不能外推到个体样本。外部数据只作风格级辅助，不替代附件本身的化合物与感官建模。

3 问题一：数据缺失条件下的感官评分

3.1 问题分析

问题一要求由 `1.csv` 的化合物数据给出 Aroma 与 Flavour 两套共 30 个感官维度的 0–6 分评分；`4.csv` 另含 20 个 taste/palate/overall 维度，本文对 50 维一并建模，结果以 30 维为核心。这项任务有三处不同于常规回归，直接决定了模型的组织方式。

第一，没有可直接学习的等级标签。`3.xlsx` 的评分卡只有 0–6 档位与公式，没有填写的分数；`4.csv` 与 `7.csv` 给出的是各自标准化后的连续值，中心化基准不同，反变换得到的等级不可比。本文因此把任务拆成两层：先回归连续感官潜变量，再用单调映射锚定到 0–6。

第二，化合物侧高维、共线且含缺失。231 个特征对应 250 个样本，同源化合物高度相关，逐维回归的方差很大；73 个缺失单元的位置也不随机，若只做中位数插补，模型可能把“未检测”读成“浓度低”。模型因此需要显式缺失掩码，并在维度之间共享信息。

第三，50 个感官维度彼此相关但并不共线。目标两两相关的中位数仅 0.016，却存在 $r = 0.98$ 的强相关对；完全独立建模会丢掉共享结构，强行低秩又会欠拟合阈值型的缺陷维度。最终方案取“多输出共享、非线性补充、等权融合”，而不是在两者中二选

一。

3.2 评价指标

设测试集有 n 个样本、S 个感官维度，$y_{i,s}$ 与 $\hat{y}_{i,s}$ 分别为观测值与预测值。连续拟合程度用宏平均决定系数、平均绝对误差与均方根误差衡量：

$$\bar{R}^2 = \frac{1}{S}\sum_{s=1}^{S}\left(1 - \frac{\sum_{i=1}^{n}(y_{i,s}-\hat{y}_{i,s})^2}{\sum_{i=1}^{n}(y_{i,s}-\bar{y}_s)^2}\right), \tag{3.1}$$

$$\mathrm{MAE} = \frac{1}{nS}\sum_{i=1}^{n}\sum_{s=1}^{S}\left|\hat{y}_{i,s}-y_{i,s}\right|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{nS}\sum_{i=1}^{n}\sum_{s=1}^{S}(\hat{y}_{i,s}-y_{i,s})^2}, \tag{3.2}$$

其中 $\bar{y}_s$ 为维度 s 的样本均值。R^2 先按维度计算再取平均，避免少数方差大的维度主导总分数；若直接把 50 维拼接后计算，方差大的维度会掩盖其余维度的拟合情况。

排序一致性用平均 Spearman 秩相关衡量，对第 s 维

$$\rho_s = 1 - \frac{6\sum_{i=1}^{n} d_{i,s}^2}{n(n^2-1)}, \qquad \bar{\rho} = \frac{1}{S}\sum_{s=1}^{S}\rho_s, \tag{3.3}$$

其中 $d_{i,s}$ 为第 i 个样本在观测值与预测值两个排序中的名次差。$\bar{\rho}$ 只关心顺序而不关心绝对水平，是判断“分级是否可用”的必要条件。

分级一致性用二次加权 Kappa 衡量[6]。设 $O_{k,k'}$ 为真实等级 k 被判为 k' 的频数，$E_{k,k'}$ 为独立假设下的期望频数，取二次权重 $W_{k,k'} = (k-k')^2/36$，则

$$\mathrm{QWK} = 1 - \frac{\sum_{k=0}^{6}\sum_{k'=0}^{6} W_{k,k'}O_{k,k'}}{\sum_{k=0}^{6}\sum_{k'=0}^{6} W_{k,k'}E_{k,k'}}. \tag{3.4}$$

二次权重使“差一档”与“差三档”的惩罚不同，适合有序等级；随机猜测的 QWK 约为 0，完全一致为 1。

这里必须交代一个口径问题。由于附件没有填写的 0–6 分数，本文的“参考分级”是把连续监督信号按训练折内 $q_{0.01}$ 与 $q_{0.99}$ 做稳健区间映射后取整得到的离散结果，它是同一信号的单调重标度，不含人工评分的绝对档位信息。因此式(3.4) 报告的 QWK 衡量的是“同一连续信号在两种离散化下的一致性”，性质上接近离散化后的秩相关，不等于与人工评分逐档吻合。本文把分级结果定位为“校准后的相对等级”，并在结果中如实报告其偏差方向。

3.3 模型构建：从基线到折外融合

3.3.1 基线模型：逐维均值与岭回归

第一个基线不使用化合物信息，只用训练集均值预测：

$$\hat{y}_{i,s}^{(0)} = \bar{y}_s, \qquad \bar{y}_s = \frac{1}{N}\sum_{i=1}^{N} y_{i,s}. \tag{3.5}$$

它的作用是给出“完全不含化合物信息”时的参照：实测 $\bar{R}^2 = -0.029$，略低于以测试集均值为参照的 0（$R^2 = 0$ 对应恰好预测均值），因此后续任何正的 R^2 都说明模型确实从化合物中取到了信息，而不是靠平凡预测撑起来的。

第二个基线是逐维岭回归与 PLS2[7;8]。设 $\boldsymbol{\beta}_s \in \mathbb{R}^P$ 为第 s 维的回归系数，c_s 为截距，$\boldsymbol{B} = [\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_S]$，则

$$\min_{\boldsymbol{B},\{c_s\}} \sum_{i=1}^{N}\sum_{s=1}^{S} \left(y_{i,s} - \boldsymbol{x}_i^{\top}\boldsymbol{\beta}_s - c_s\right)^2 + \lambda\|\boldsymbol{B}\|_F^2. \tag{3.6}$$

式(3.6) 通过一个共享的正则化强度降低小样本下的方差；PLS2 则把 $\boldsymbol{B}$ 约束为低秩，用少量潜变量同时解释多个感官维度，是多任务共享最简单的形式。两者都不使用缺失指示与风格信息，作为后续改进的对照。

3.3.2 改进模型：缺失指示与风格先验

改进模型加入两条数据事实。

其一是缺失。在训练折内做中位数插补的同时，把“该列是否缺失”作为 0/1 指示特征拼入特征向量，使模型能区分“浓度低”与“未检测”。其二是风格。`1.csv` 自带风格标签 z_i，而同一化合物谱在不同风格下的感官期望并不相同，因此把风格信息作为附加特征：

$$\tilde{\boldsymbol{x}}_i = [\boldsymbol{x}_i;\ \boldsymbol{M}_i;\ \boldsymbol{s}_{z_i}], \tag{3.7}$$

其中 $\boldsymbol{M}_i$ 为第 i 个样本的缺失指示向量，$\boldsymbol{s}_{z_i}$ 为风格的 one-hot 编码或该风格在训练折内的感官均值（目标编码）。目标编码用留一与平滑（平滑系数 10）估计，避免把当前样本的标签泄漏进特征。

需要说明，风格先验不是用标签作弊：风格是 `1.csv` 的既有列，且在真实品评流程中，品评员在打分前已知酒的风格。为量化它的作用，本文同时报告仅用化合物与加入风格先验两组结果（表 3.2）。

3.3.3 最终模型：五模型折外等权融合

单一模型对共线的化合物与其中的非线性关系都不够稳健。最终模型用五类互补的学习器得到折外预测：PLS2（低秩多任务）、岭回归（线性）、极端随机树与随机森林（非线性、原生多输出）、LightGBM（逐维提升）。记第 ν 个学习器对样本 i、维度 s 的折外预测为 $\hat{y}_{i,s}^{(\nu)}$，学习器集合为 $\mathcal{M}$，比较两种融合：

$$\hat{y}_{i,s}^{\text{avg}} = \frac{1}{|\mathcal{M}|} \sum_{\nu \in \mathcal{M}} \hat{y}_{i,s}^{(\nu)}, \qquad \hat{y}_{i,s}^{\text{stack}} = \sum_{\nu \in \mathcal{M}} \omega_{\nu,s} \hat{y}_{i,s}^{(\nu)} + b_s, \tag{3.8}$$

其中 $\omega_{\nu,s}$ 在折外预测上用岭回归拟合。等权融合不估计额外权重，因而没有第二层过拟合风险；堆叠可以按维度分配权重，但元学习器是在训练折的折外预测上拟合的，这些预测又来自包含当前测试折样本的模型，存在乐观偏置。实测等权融合的 $\bar{R}^2$ 为 0.227，高于堆叠的 0.216，且折间方差更小；即便带着上述偏置，堆叠仍未超过等权，本文因此以等权融合为最终方案，堆叠作为对照保留。

融合之所以有效，是因为五类模型在不同维度上各有胜负：线性模型在酸度、苦味这类与化合物近乎单调相关的维度上更好，树模型在酒花与麦芽的复合香型上更好，等权平均让两者的误差互相抵消，而不需要额外的权重估计。

这一增益的幅度必须说清。五个单体的宏平均 $\bar{R}^2$ 依次为：极端随机树 0.223、随机森林 0.217、岭回归 0.162、PLS2 0.141、LightGBM 0.137，逐维均值基线为 -0.029。等权融合的 0.227 相对最强单体（极端随机树）只高 0.004，两者折间误差棒重叠，因此融合的收益不能表述为“显著更高”，它的实际价值在于折间标准差更小与逐目标表现更均衡。堆叠的情况同样需要交代：Ridge 堆叠在 RMSE（0.469）与 Spearman（0.433）上均以 0.001 量级微弱优于等权融合，仅 $\bar{R}^2$（0.216）落后。本文以 $\bar{R}^2$ 为主、并计入堆叠的乐观偏置与更大的折间方差，选择等权融合；这属于近似打平下的取舍，而非全面占优。

3.3.4 分级校准：由感官潜变量到 0–6 分

连续预测存在向均值收缩的问题，直接做 min-max 会把所有样本挤到中间几档。本文先在训练折内拟合单调映射：用保序回归 g_s 把预测值映射到观测的连续值，再做稳健区间映射，

$$\hat{k}_{i,s} = \text{round}\left(6 \cdot \frac{g_s(\hat{y}_{i,s}) - q_{0.01,s}}{q_{0.99,s} - q_{0.01,s}}\right), \qquad \hat{k}_{i,s} \in \{0, \ldots, 6\}, \tag{3.9}$$

其中 $q_{0.01,s}$、$q_{0.99,s}$ 为训练折内 $g_s(\hat{y}_{\cdot,s})$ 的 1% 与 99% 分位数，越界值截断到端点。保序回归只要求单调、不假设线性，能够纠正收缩而不改变样本间的顺序；稳健区间映射只负责把校准后的值锚定到 0–6 档。

分级结果对校准方案并不免疫。本文另对 raw min-max、quantile rank、quantile map、linear recalibration 与 Gaussian latent 五种替代校准做了同样的评估，六种方案的宏平均 QWK 分布在 0.276（quantile rank）到 0.441（quantile map）之间，跨度 0.165，说明分级结论确实依赖这一层假设。本文仍以保序回归为主方案，理由是它同时给出最低的等级平均绝对误差（0.83 档；quantile map 为 0.95 档）：分级结果会作为问题三感官画像的输入，逐档偏差对下游的影响大于整体秩一致性。若下游只关心排序而不关心档位，quantile map 的 QWK 更高，是更合适的选择，这一点在讨论中作为备选方案保留。

3.4 实验设置

数据划分与评估。按样本做 5 折、重复 3 次（随机种子 42），共 15 折；插补、标准化、分位数变换、保序校准与超参数选择全部在训练折内完成，验证折与测试折只做变换。

超参数在外层训练折内用内层交叉验证选择，不跨折固定：岭回归的 α 在 $[10^0, 10^6]$ 上取 13 点对数网格，内层 5 折；PLS 成分数在 2–20 之间，内层 5 折；极端随机树与随机森林的叶节点数在 $\{1, 2, 4\}$ 中选，调参时用 200 棵、最终 500 棵；LightGBM 固定 400 棵、学习率 0.03、叶节点 15、行与列采样各 0.8、L_2 正则 1.0；堆叠元学习器为 RidgeCV，$\alpha \in [10^{-3}, 10^2]$、内层 3 折。

缺失模拟。除自然缺失外，在测试集上按比例随机遮蔽化合物构造 MCAR 情形（5%、10%、20%、30%），并构造一种非随机缺失（MAR）情形：按 `ethanol..v.v.` 的四分位分层决定遮蔽概率，使高酒精度样本更容易被遮蔽，平均缺失率 24.77%。前者检验插补与缺失指示在随机机制下的效果，后者检验缺失与观测值相关时是否产生系统偏差。

对照设置。共五组：（1）逐维均值；（2）逐维岭回归；（3）多输出岭回归与 PLS2；（4）式(3.8) 的等权融合；（5）去掉风格先验、去掉保序校准或去掉树模型的消融版本。所有对照在同一划分上比较，避免“换了数据又换了模型”。

3.5 结果与分析

三种路线的重复交叉验证结果见表 3.1。最终模型的宏平均 R^2 为 0.227，相对逐维岭回归的 0.162 提升 0.065；平均 Spearman 从 0.373 升到 0.432；MAE 与 RMSE 分别下降 5.7% 与 5.1%。

表 3.1 问题一三种路线的重复交叉验证结果（5 折 × 3 次重复，50 维宏平均）

模型	$\bar{R}^2$	MAE	RMSE	平均 Spearman	QWK
基线：逐维岭回归	0.1617	0.3622	0.4946	0.3728	—
改进：岭回归 + 缺失指示 + 风格先验	0.1855	0.3542	0.4855	0.3927	—
最终：五模型折外等权融合 + 保序校准	**0.2270**	**0.3415**	**0.4695**	**0.4318**	0.3756

表中前四列为 15 折的折间均值，QWK 只对最终方案报告——基线与改进尚未做分级校准，报告 QWK 没有可比性。最终模型的折间标准差为 R^2 0.021、Spearman 0.024、RMSE 0.018、MAE 0.011，说明结果不依赖某一次划分。

改进的幅度不大，但方向一致。把 50 个维度拆开看，$R^2 > 0.3$ 的有 14 个，最强的是 acidity（0.690）、alcohol（0.678）、lactic（0.648）、acetic（0.635）与 bitternes（0.604）；最弱的是 barnyard（−0.039）、stale_hops（−0.032）与 clove（−0.005）。这一分布与化学直觉一致：酸度、酒精度、苦味有明确的化学载体（有机酸、乙醇、异 α 酸），其浓度与感官强度近似单调；而 barnyard 由 4-乙基苯酚与 4-乙基愈创木酚等痕量酚类决定，clove 由 4VG 决定，二者都只在超过阈值后才被感知，且在同一风格内部变异很小，231 个化合物特征提供不了足够的区分信息。缺陷维度的可预测性弱，这一点在问题二中会以另一种形式再次出现。

风格先验的消融结果见表 3.2。它在岭回归上带来 +0.024 的提升，在融合模型上只带来 +0.012。原因是融合模型中的树模型已能从化合物谱间接识别风格，风格先验的边际信息被吸收掉了。综合考虑后，最终交付以仅用化合物的融合模型为主，加入风格先验的版本作为消融报告，以免把“用标签换精度”当成主要贡献。

表 3.2 风格先验的消融（$\bar{R}^2$）

模型	仅用化合物	加入风格先验	变化
逐维岭回归	0.1617	0.1855	+0.0238
五模型折外等权融合	0.2270	0.2388	+0.0118

缺失条件下的退化见表 3.3。以自然缺失（0.13%）下的 $R^2 = 0.2264$ 为基准，随机遮蔽 5%、10%、20%、30% 时 R^2 分别相对下降 3.5%、6.3%、11.5%、19.3%，RMSE 相对上升 0.7%、1.2%、2.3%、3.8%；退化随缺失率近似单调，没有出现断崖。非随机缺失（平均 24.77%）下的下降为 10.9%，与同量级的随机缺失（20% 时 11.5%）接近，说明在本文的遮蔽机制下没有明显的额外偏差。

表 3.3　缺失模拟下的性能变化（基准为自然缺失，$\bar{R}^2 = 0.2264$）

情形	平均缺失比例	R^2 相对变化	RMSE 相对变化
自然缺失	0.13%	0	0
MCAR 5%	5.00%	−3.46%	+0.70%
MCAR 10%	10.00%	−6.33%	+1.15%
MCAR 20%	20.00%	−11.46%	+2.28%
MCAR 30%	30.00%	−19.33%	+3.75%
MAR（按酒精度分层）	24.77%	−10.89%	—

分级校准的效果体现在等级分布上。直接对融合预测做 min-max 时，被预测为 0 级的样本仅占 7.6%；加保序回归后升至 11.3%，参考分级中 0 级占 23.3%。校准明显缓解了“向中间档压缩”，但仍低估尾部，QWK 为 0.376，属于中等一致。这与前面的口径说明相符：模型能保持样本间的相对顺序与等级单调性，但不足以复现人工评分的绝对档位分布。

3.6　讨论

问题一的主要困难不在模型复杂度，而在标签不可直接观测。本文用“连续监督加有序校准”绕开了空白评分卡的限制，代价是最终 0–6 分数的绝对水平依赖校准锚点。稳妥的表述是：在给定校准方案下，模型保持了样本间的相对顺序与等级单调性；若要报告绝对等级精度，需要原始评分或专家复核数据。

其次是低秩假设的边界。多输出共享假定不同感官维度由少量共同因子驱动，这与目标间相关结构的中位数偏低、存在少量强相关对的事实相符，但对阈值型维度并不成立，表现为这类维度的 R^2 接近 0 甚至为负。可行的改进是允许部分维度使用独立残差项，或在低秩模型与逐维模型之间做模型平均，本文未进一步展开。

最后是缺失机制。掩码指示与折内插补在随机缺失下近似无偏，在非随机缺失下只能减轻偏差而不能消除。若后续能拿到缺失原因的元数据（例如某化合物未检测而非浓

度为零），应把缺失原因作为额外变量纳入模型，而不是用一个 0/1 掩码近似。

4 问题二：化合物——风味关联分析

4.1 问题分析

问题二要求为每个感官维度给出 Top-3 关键因素化合物，并论证其稳定性与化学合理性。它要的不是预测精度最高的模型，而是在 231 个高度共线的化合物中找出对某个维度既有统计支持、又有化学解释的少数变量。

可用的信息有三类：`2.csv` 刻画“哪些化合物共同变化”，`1.csv` 刻画“样本间差异有多大”，`6.csv` 刻画“已有数据中是否观察到对应关系”。可用的 Top-3 应在这三类信息上都不出现明显矛盾，而不是只在一张相关矩阵上排到前列。

主要困难是共线导致的排序不稳。同一代谢路径或同一酒花组分产生的化合物彼此高度相关，单个化合物的边际相关会被相关化合物“分摊”，重采样时名次相邻的几个化合物互相挤占 Top-3，“取绝对值最大的三个”得到的是一份随样本波动的名单。其次是相关与因果的区分：共表达图上的边可能来自共同上游调控、批次差异或样品制备，不能直接当作化学作用。

本文因此分三步处理：先构建共表达图刻画模块结构，再在图上排序得到候选，最后用多方法秩融合、bootstrap 重采样[9] 与化学类别核对确定 Top-3，并把稳定性作为独立信息报告，而不是用它二次筛选。

4.2 评价指标

与问题一不同，本题没有预测精度意义上的“真值”，评价必须落在结构、排序与外推一致性三个层面。

图层面用模块度 Q、社区数、孤立点数与方案间的调整兰德指数（ARI）衡量。Q 越大说明模块结构越清晰，但 Q 会随边数增加而虚高，因此必须与孤立点数一起看：把所有节点连成一张近乎完整的图也能得到很高的 Q，却失去了筛选意义。

排序层面用 bootstrap 入选频率与方法间 Jaccard 系数。对第 s 个感官维度重复 B 次有放回重采样，第 b 次得到的 Top-3 集合记为 $\mathcal{T}_s^{(b)}$，则化合物 j 的入选频率为

$$\pi_{j,s} = \frac{1}{B}\sum_{b=1}^{B} \mathbf{1}\left\{j \in \mathcal{T}_s^{(b)}\right\}. \tag{4.1}$$

两种方法 ν 与 ν' 给出的 Top-3 集合之间的一致性为

$$J\left(\mathcal{T}_s^{(\nu)}, \mathcal{T}_s^{(\nu')}\right) = \frac{\left|\mathcal{T}_s^{(\nu)} \cap \mathcal{T}_s^{(\nu')}\right|}{\left|\mathcal{T}_s^{(\nu)} \cup \mathcal{T}_s^{(\nu')}\right|}. \tag{4.2}$$

$\pi_{j,s}$ 衡量单条目在重采样下的稳定性，J 衡量不同建模方法之间的一致性，二者缺一不可：一组 Top-3 可能单独看都很稳（π 高），但方法之间完全不重合（J 低），说明结论依赖具体的建模假设。

外推一致性用 `6.csv` 校验。`6.csv` 给出 44 个化合物与指标同 50 个感官属性的两两相关，本文用它与排序结果比对符号与名次，并注意它本身也是边际相关，不控制共线，因此只能验证方向与量级，不能当作独立复现。

这里需要说明一处数据口径。题面称 `2.csv` 为皮尔逊相关，而附件的数据说明写的是 Spearman，两者不一致；本文只使用 $|r|$ 的相对大小构建图，不解释系数的绝对强度，故这一不一致不影响结论。`6.csv` 按 Spearman 使用，与方法 A 的口径一致，这也是后文“方法 A 与 `6.csv` 的秩相关接近 1”的原因。

4.3 模型构建：从共表达图到秩融合

4.3.1 共表达图的构建与社区结构

设化合物 j 与 j' 的相关系数为 $r_{j,j'}$（取自 `2.csv`），邻接矩阵 $\boldsymbol{A}$ 的元素定义为

$$a_{j,j'} = \begin{cases} 1, & |r_{j,j'}| \geq \eta \text{ 或 } j' \in \mathcal{N}_K(j), \\ 0, & \text{否则}, \end{cases} \qquad a_{j,j} = 0, \tag{4.3}$$

其中 $\mathcal{N}_K(j)$ 为与 j 相关性最强的 K 个邻居。阈值 η 在实际数据上很难同时满足“不产生大量孤立点”与“模块清晰”两个要求：取 $|r| \geq 0.5$ 时图只剩 645 条边、却有 48 个孤立点（占 21%），这些孤立点正是后续无法排序的化合物。本文因此改用 K 近邻图，它保证每个节点都有边，K 由验证集上的模块度与下游稳定性共同选定。

图的拉普拉斯矩阵与度为

$$\boldsymbol{L} = \boldsymbol{D} - \boldsymbol{A}, \qquad d_j = \sum_{j'=1}^{P} a_{j,j'}, \tag{4.4}$$

其中 $\boldsymbol{D} = \mathrm{diag}(d_1, \ldots, d_P)$。对 $\boldsymbol{L}$ 做特征分解可得到低频模块结构[10]，本文用模块度与社区划分检查图是否把已知的化学类别分开。

$K = 10$ 时得到 231 个节点、1,683 条边（密度 0.063）、8 个社区，模块度 $Q = 0.586$。与两个对照相比：$K = 5$ 时 865 条边、$Q = 0.703$，模块度更高但边数少一半，Top-10 与 Top-5 两种方案的社区划分 ARI 只有 0.558，说明结论对 K 并不稳健，这本身就是一个需要报告的稳定性事实；$|r| \geq 0.5$ 时 645 条边、$Q = 0.663$，但代价是 48 个孤立点。综合考虑，本文取 $K = 10$ 为主方案：它在保留全部节点的前提下维持了可辨识的模块结构。

8 个社区与化学类别的对应关系见表 4.1。需要说明的是，社区并不严格等于化学家族：同一社区内往往混有酯、萜与醇，这是因为它们受同一发酵条件（温度、酵母菌株、酒花添加量）共同驱动。因此社区只作为“哪些化合物应一起考虑”的先验，最终的化学合理性仍需逐化合物核对。

表 4.1　共表达网络的 8 个社区及其化学构成

社区	节点数	主要来源与类别	代表成员
C1	40	酵母与酒花：酯、萜、醇、醛	E-nerolidol、2,3-dihydrofarnesol
C2	34	酒花：萜类与酯	nerol oxide、epicubenol
C3	32	酒花、酵母与野生菌：酯、挥发性酚	ethyl phenylacetate、neryl formate
C4	29	酵母：酯、醇、硫、理化指标	ethanol、isopentyl acetate
C5	28	麦芽与酵母：醛、呋喃、吡嗪、双乙酰	diacetyl、2-pentylfuran
C6	24	酵母与酒花：以酯为主（16/24）	2-methylbutyl octanoate
C7	22	酵母与酒花：醇、酯、萜	3-methyl-2-hexanol、o-cresol
C8	22	酒花与香料：以萜类为主（11/22）	isoborneol、terpinen-4-ol

4.3.2　基线方法：边际相关排序

最直接的 Top-3 是逐化合物计算与目标感官维度的边际相关，取绝对值最大的三个：

$$w_{j,s}^{(0)} = \left|\mathrm{Spearman}\left(x_{\cdot,j}, y_{\cdot,s}\right)\right|, \qquad \mathcal{T}_s^{(0)} = \operatorname*{Top3}_j \; w_{j,s}^{(0)}, \tag{4.5}$$

其中 $x_{\cdot,j}$ 为第 j 个化合物的样本向量，$y_{\cdot,s}$ 为第 s 个感官维度的评分向量。该基线完全可复现、解释直接，但恰好暴露出本题的三个困难：共线化合物会轮流占据前列，边际相关分不清直接关联与经由第三变量的间接关联，单条相关系数对缺失与异常值也敏感。

4.3.3 改进方法：共表达图上的拉普拉斯平滑

共表达图提供了“哪些化合物应一起被考虑”的先验。把基线的重要性向量在图上做平滑：

$$\tilde{\boldsymbol{w}}_s = (\boldsymbol{I} + \alpha \boldsymbol{L})^{-1} \boldsymbol{w}_s^{(0)}, \tag{4.6}$$

其中 $\alpha > 0$ 控制平滑强度。式(4.6) 的含义是：一个化合物的重要性不仅取决于自身的边际相关，还取决于与它强连接的邻居。孤立的高相关点会被适度压低，成模块出现的高相关化合物则被整体保留。与直接对相关系数设阈值相比，这种做法不切断弱相关边，而是让重要性沿图扩散，因此对阈值的选择不敏感。

α 由验证集上的 Top-3 稳定性选定，不固定为 1：$\alpha \to 0$ 时退化为基线，α 过大则所有化合物的重要性被拉平、Top-3 失去区分度。本文取 $\alpha = 0.3$，这一设定使改进方法始终把基线作为特例。

4.3.4 最终方法：五方法秩融合与稳定性选择

单一方法对共线结构敏感，因此并列保留五种互补方法，在排序层面做融合：

（A） **边际 Spearman**：逐化合物计算与目标维度的 Spearman 相关，在每个目标内做 BH 校正后按 $|r|$ 排序；

（B） **弹性网**：逐目标做弹性网回归，内层 4 折交叉验证在正则化强度与 l_1 比例网格上选参，用系数绝对值作为重要性；

（C） **极端随机树**：逐目标拟合 300 棵树（深度 8、叶节点 3、特征子采样 $\sqrt{P}$），用不纯度下降作为重要性；

（D） **LightGBM 的 SHAP 值**[11]：逐目标做 5 折折外拟合（150 棵树），用折外平均 |SHAP| 衡量每个化合物对单个感官维度的贡献；

（E） **网络平滑**：把方法 A 的重要性沿共表达图做一步邻居平滑（系数 0.30）。

记方法集合为 $\mathcal{M} = \{A, B, C, D, E\}$，第 ν 种方法给出的重要性为 $\tilde{w}_{j,s}^{(\nu)}$，在每个目标内排秩得 $R_{j,s}^{(\nu)}$，用 Borda 秩平均融合：

$$\bar{R}_{j,s} = \frac{1}{|\mathcal{M}|} \sum_{\nu \in \mathcal{M}} R_{j,s}^{(\nu)}, \qquad w_{j,s}^{*} = 1 - \frac{\bar{R}_{j,s} - 1}{P - 1}, \tag{4.7}$$

其中 $w_{j,s}^{*} \in [0, 1]$，Top-3 取 $\bar{R}_{j,s}$ 最小的三个化合物。C 与 D 只产生无符号的重要性，融

合前用 A 的边际相关符号为其赋号，得到带方向的共识分数。等权秩平均不设可调权重，避免在小样本验证集上调权导致二次过拟合。

这里有两处口径需要如实说明。其一，方法 D 在排序分析中用 5 折折外 SHAP，在 bootstrap 中为控制耗时改用全样本 SHAP，因此秩与入选频率反映的是不同口径下的贡献，二者不可逐项对照，比较应以融合结果为准。其二，方法 E 只改变同一目标内重要性的分布形状，不引入新的数据信息，因此仅作为类别视角的审计，不作为“更优”的证据。

4.4 实验设置

数据与划分。样本按 `beer` 分层划分训练、验证与测试集，所有方法在同一划分上比较；缺失值在训练折内插补，测试折只做变换。

主要参数。$K = 10$；图平滑 $\alpha = 0.3$；弹性网用内层交叉验证选正则化强度与 l_1 比例；树模型 300 棵（bootstrap 时为 60 棵）；LightGBM 150 棵（bootstrap 时 60 棵）；bootstrap 重采样 $B = 500$；入选频率只用于报告稳定性，不参与筛选；随机种子 42。

对照与评价分四层：（1）预测层，各方法对感官维度的交叉验证误差；（2）排序层，Top-3 的 bootstrap 入选频率；（3）一致层，方法间 Jaccard 系数；（4）化学层，Top-3 是否落在合理的化合物类别、方向是否与已知代谢路径一致。四层都不出现明显矛盾，才把该组 Top-3 作为最终结果。

4.5 结果与分析

500 次 bootstrap 下的纯数据 Top-3 见表 4.2 的中间列。平均入选频率为 0.525，中位数 0.47；150 个条目中 29 个达到 0.8、67 个达到 0.5。方法间的平均 Jaccard 系数为 0.313，其中边际 Spearman 与网络平滑最高（0.74），边际 Spearman 与弹性网最低（0.20）——后者反映线性正则化与一元相关在共线结构下给出的名单差异最大。

稳定性需要分层看。没有任何一个感官维度的三个条目全部达到 0.8；6 个维度的三个条目都达到 0.5，24 个维度至少两个条目达到 0.5，22 个维度至少一个条目达到 0.8。也就是说，“单个化合物稳定”比“整组 Top-3 稳定”常见得多，因此 Top-3 必须带着入选频率一起报告，只给三个名字会掩盖它对重采样的敏感程度。

图构造方案的扰动同样影响结论：Top-5 与 Top-10 两种 K 近邻图的社区划分 ARI 只有 0.558，硬阈值 $|r| \geq 0.5$ 会产生 48 个孤立点。这说明“Top-3”的稳定性不仅受重采样影响，也受图构造方式影响，本文把 $K = 10$ 作为主方案的依据是它同时满足“无孤立点”与“模块可辨识”，而非它在某个单项指标上最优。

4.6 稳定性与化学合理性论证

4.6.1 纯数据结果与机制导向结果的分工

统计上排序最靠前的化合物，未必是化学上最该关注的化合物。对双乙酰、DMS 与反式-2-壬烯醛这三个缺陷维度，纯数据 Top-3 都没有选到同名直接化合物：`diacetyl` 的融合名次为 120.8，`DMS` 为 86.5，`t2n` 为 91.4。选中的是蛋白、色度、总硫等风格或物化代理——它们与缺陷维度同受风格与工艺驱动，因而在相关结构上更显著。

这一现象本身是重要发现，而不是方法失败。原因有三：其一，多数样本的缺陷浓度低于阈值，剂量—响应关系被压缩，相关自然变弱；其二，缺陷感知受整体风格与其它缺陷的掩蔽影响，人工评分并不线性反映浓度；其三，`4.csv` 是标准化后的连续值，面板打分的噪声被相对放大。

因此本文把结果分成两栏并列报告（表 4.2）。左栏为纯数据 Top-3，回答“哪些化合物最能预测该感官维度”；右栏为机制导向 Top-3，在融合分数上叠加文献先验后得到，回答“哪些化合物在化学上最应被关注”。前者是主结果，后者是机制审计，两者不是替代关系。把相关当成因果、只报右栏，是这类题目最常见的失分点。

表 4.2　纯数据 Top-3 与机制导向 Top-3 的对照（8 个代表性维度）

感官维度	纯数据 Top-3	机制导向 Top-3
diacetyl	pentyl octanoate；ethyl decanoate；β-phellandrene	diacetyl；pentyl octanoate；ethyl decanoate
dms	protein；color；total sulfur	total sulfur；SO_2；DMS
t2n	glycerol；α-phellandrene；β-phellandrene	E-2-nonenal；dimethoxy-E-citral；Z-dihydro-apofarnesal
X4vg	4-vinylguaiacol；neryl formate；prenyl isobutyrate	4-vinylguaiacol；4-ethyl-guaiacol；4-ethyl-phenol
A_esters_fruity	β-phellandrene；epicubenol；humulene epoxide II	neryl formate；ethyl decanoate；2-phenylethyl butyrate
A_hops_citrus	total hop aroma；cis-dihydro-β-terpineol；citronellol	citronellol；geraniol；humulene epoxide II
A_malt_all	color；caloric value；pH	2-acetylfuran；5-methylfurfural；furfural
bitternes	ethyl octanoate；iso-alpha acids；ethyl decanoate	iso-alpha acids；ethyl octanoate；ethyl decanoate

机制先验的强度用 λ 控制，本文取 $\lambda = 0.5$。这个取值需要明确其性质：它正好是使双乙酰、DMS 与反式-2-壬烯醛三个直接化合物同时进入 Top-3 的最小值，属于“强先验”情景，不是由数据优化得到的最优值。λ 的敏感性见表 4.3：$\lambda = 0$ 时机制导向退化为纯数据，重合率为 1.0；$\lambda = 0.5$ 时与纯数据 Top-3 的重合率降到 0.387，平均 bootstrap 稳定性从 0.525 降到 0.303。也就是说，机制导向的代价是可量化的：它用约 40% 的排序稳定性和 60% 的名单重合，换取对三个缺陷维度的化学可解释性。

表 4.3　机制先验强度 λ 的敏感性

λ	与纯数据 Top-3 重合率	平均入选频率	直接化合物条数	与 `6.csv` 的重合率
0.0	1.000	0.525	5	0.460
0.1	0.780	0.480	5	0.393
0.2	0.633	0.428	5	0.387
0.5	0.387	0.303	9	0.313

4.6.2　化学合理性核对

网络社区与已知化学家族基本对齐（表 4.1）：C2 与 C8 富集酒花萜类，C4 与 C6 富集酵母酯类与醇类，C5 富集麦芽来源的醛、呋喃与吡嗪。Top-3 中有三条链条可以逐环节核对。

苦味。`bitternes` 的两栏都给到异 α 酸，与化学事实一致：异 α 酸是酒花 α 酸经异构化生成的苦味物质，直接决定苦度。需要指出，这一条中“两栏一致”部分属于定义性一致——`6.csv` 中的 Iso-alpha acids 与 `1.csv` 的 `bitterness` 列同源，因此它不构成独立证据。

挥发性酚。`X4vg` 的两栏都落在 4-乙烯基愈创木酚及其衍生物上，对应阿魏酸经酵母 Pad1 脱羧酶生成 4VG 的路径，其阈值约 0.2 mg/L，在非小麦风格中即为酚缺陷。这一条同时满足类别匹配、来源匹配与剂量可算，是本文最可靠的一组 Top-3。

酒花柑橘香。`A_hops_citrus` 的两栏都落在香叶醇、里那醇与香茅醇上。三者均为单萜醇，且香叶醇在发酵中可转化为香茅醇，二者的协同是柑橘香的主要来源，因此按“家族”而非单化合物解读更合适。

反过来，酯香维度 `A_esters_fruity` 的纯数据 Top-1 是 β-菲兰烯（入选频率 0.782），一种酒花萜烯，而不是任何酯类。这说明“果香由酯类决定”这一教科书结论在本数据中并不成立：酯类与萜烯受同一酒花添加与发酵条件驱动，边际相关上萜烯反而更强。这条反例提示，Top-3 的名字必须与化学类别、剂量、阈值一起读，不能只看排名。

类别富集检验的结果也支持“只作辅助证据”的定位：Top-3 层面有 3 个类别显著富集（理化指标，富集倍数约 17.8，$q = 0.0023$），Top-10 层面有 9 个显著（富集倍数 8.9，$q = 0.00085$；有机酸约 23.1，$q = 0.027$）。显著项集中在理化指标与有机酸，恰好是题面所说的“由多化合物加和得到的派生属性”，说明这类列在共表达图中天然处于枢纽位置，容易被选中，解释时应与具体组分对照阅读。

最后一点可作为与问题一的交叉检查：某化合物若在此被判为某维度的关键因素，却在问题一的多任务模型中没有稳定系数，则两者至少有一个需要复查。本文把这种不一致作为诊断信息保留——缺陷维度在问题一中 R^2 接近 0 或为负，正与本节的“直接化合物的边际信号弱于代理”互为印证。

4.7 讨论

问题二的结论受三方面限制。

第一，相关不等于因果。共表达图上的边可能来自共同上游调控、批次差异或样品制备，本文用多方法融合与 `6.csv` 交叉校验降低了这种风险，但不能证明因果。若要用干预实验或代谢网络先验替代纯相关图，需要额外的实验数据，本文不具备。

第二，化合物注释与类别划分依赖 `8.xlsx` 与文献，若注释有误，化学合理性判断会跟着错。本文把类别核对过程写进正文与附录，便于复查；但这只能降低而不能消除注释带来的不确定性。

第三，Top-3 是“给定数据与给定感官维度下的紧凑摘要”，不是“只有这三个化合物重要”。排名第四、第五的化合物在特定风格或特定缺陷场景中可能更关键，实际使用时不应把 Top-3 当作硬阈值。同样，$\lambda = 0.5$ 的机制导向结果只适用于机制审计，不能作为“最强预测因子”的结论引用。

5 问题三：“风味指纹”与风格条件生成

5.1 问题分析

问题三包含三个相互关联的子任务：以 `tasting_category_fine` 为条件学习风格生成模型，使给定风格（如 Tripel、Kriek、Lambic）能生成合理的化合物谱；由生成的化合物谱给出对应的感官画像，即“风味指纹”；完成跨风格迁移，例如把 Pils/Lager 的化合物谱迁移为 Tripel 风格，同时保证 DMS、双乙酰、4VG、反式-2-壬烯醛与 stale hops 等缺陷化合物不恶化。

与问题一、二相比，这里没有唯一正确的答案。同一风格的不同酒在化合物谱上差

异很大，生成模型不能只记住训练样本；而风格标签在 7.csv 中分布不均，Tripel 有 28 个样本，Kriek 10 个、Lambic 11 个，最少的 Faro 只有 3 个，逐风格单独建模必然过拟合。这两点决定了模型必须做到“参数少、协方差可收缩”。

本文没有采用条件变分自编码器或条件 GAN。这类模型在样本充足时拟合能力强，但在 $N = 250$、$G = 22$ 的规模下，其参数量与训练方差都远超数据所能支撑的范围，且生成结果难以做逐化合物的阈值约束。本文改用“条件高斯 copula 学风格分布、高斯最优传输做跨风格迁移、风格感知上限约束缺陷”的路线：三者的参数都可从 250 个样本稳定估计，每一步都能写出闭式形式，缺陷约束也能直接作用在指定列上。

评价上本文不追求单一指标最优。生成质量本就无真值，风格分类器可以因模式崩塌而虚高，多样性可以因生成不合理化合物而虚高，缺陷比例可以靠把风味一起压没来降低。因此评价拆成分布保真、风格保真、多样性、缺陷控制与感官一致五个维度，同时报告。

5.2 风味指纹与评价指标

以 7.csv 的 tasting_category_fine 为风格标签 z_i，通过 beer 列与 1.csv 连接，得到化合物谱与风格的配对数据；属于风格 g 的样本集合记为 $\mathcal{D}_g$。本文把风格 g 的风味指纹定义为其化合物谱均值与感官画像均值的组合：

$$\mathcal{F}_g = (\bar{\boldsymbol{x}}_g,\ \bar{\boldsymbol{y}}_g), \qquad \bar{\boldsymbol{x}}_g = \frac{1}{|\mathcal{D}_g|}\sum_{i\in\mathcal{D}_g}\boldsymbol{x}_i, \quad \bar{\boldsymbol{y}}_g = \frac{1}{|\mathcal{D}_g|}\sum_{i\in\mathcal{D}_g}\boldsymbol{y}_i. \tag{5.1}$$

该定义不替代完整的生成分布，而是给生成结果提供一个可比较的“风格中心”：生成样本既要接近 $\bar{\boldsymbol{x}}_g$，又要保留风格内部的合理变异，不能退化为均值复制。

五个评价维度如下。

分布保真用 RBF 核的最大均值差异衡量：

$$\mathrm{MMD}^2 = \frac{1}{n^2}\sum_{i,i'}k(\boldsymbol{x}_i,\boldsymbol{x}_{i'}) + \frac{1}{m^2}\sum_{j,j'}k(\tilde{\boldsymbol{x}}_j,\tilde{\boldsymbol{x}}_{j'}) - \frac{2}{nm}\sum_{i,j}k(\boldsymbol{x}_i,\tilde{\boldsymbol{x}}_j), \tag{5.2}$$

其中 $\tilde{\boldsymbol{x}}$ 为生成样本，$k(\cdot,\cdot)$ 为 RBF 核，核宽按中位启发式取。

风格保真用真实数据训练的风格分类器在生成样本上的 top-1 命中率，辅以生成样本到目标风格中心的马氏距离。多样性用覆盖度与精确度：以真实样本留一最近邻距离的中位数为阈值，覆盖度是“至少被一个生成样本落入该阈值”的真实样本比例；以该距离的 95% 分位为阈值，精确度是“到真实集最近邻距离不超过该阈值”的生成样本

比例。缺陷控制用各缺陷列超过给定阈值的比例。感官一致用问题一的模型为生成的化合物谱预测感官画像，再与 $\bar{\boldsymbol{y}}_g$ 比较 RMSE 与 Pearson 相关。

五项必须同时报告。只提高风格命中率可能意味着模式崩塌——生成样本都挤在风格中心附近；只提高多样性可能生成不合理的化合物；只压低缺陷比例可能把该风格应有的风味一起压掉。本文用这五项构成一张对照表，避免用单一指标下结论。

5.3 模型构建：从风格均值到缺陷约束

5.3.1 基线方法：风格均值与全局协方差采样

最简单的风格条件生成器是“风格均值加高斯噪声”：对每个风格 g 估计均值 $\boldsymbol{\mu}_g$，用所有风格合并后的协方差 $\boldsymbol{\Sigma}_{\text{pool}}$ 注入随机性：

$$\tilde{\boldsymbol{x}}^{(g)} = \boldsymbol{\mu}_g + \boldsymbol{\Sigma}_{\text{pool}}^{1/2}\boldsymbol{z}, \qquad \boldsymbol{z} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}). \tag{5.3}$$

它的变体是“全局协方差加风格均值平移”，即保留全局相关结构，只把均值移到目标风格。两者训练快、可复现，能给出风格中心与基本变异，但无法刻画风格内部协方差的差异，在零膨胀的长尾化合物上也容易生成不合理的极端值。

5.3.2 改进方法：条件高斯 copula

化合物浓度具有强零膨胀与长尾，直接对浓度建高斯模型会生成负值。本文先用经验分布把每个化合物映射到标准正态分数：

$$z_{i,j} = \Phi^{-1}\left(F_j(x_{i,j})\right), \tag{5.4}$$

其中 F_j 为第 j 个化合物在训练集上的经验分布函数，Φ 为标准正态分布函数。变换后各列边际为正态，风格间的差异只剩均值与相关结构。

对风格 g 估计均值 $\boldsymbol{\mu}_g$ 与协方差 $\boldsymbol{\Sigma}_g$。当 $|\mathcal{D}_g|$ 较小时，样本协方差不可靠，用收缩估计：

$$\boldsymbol{\Sigma}_g^{(\lambda)} = (1-\lambda)\hat{\boldsymbol{\Sigma}}_g + \lambda\boldsymbol{\Sigma}_{\text{pool}}, \qquad \lambda = \frac{n_0}{n_0 + |\mathcal{D}_g|}, \tag{5.5}$$

其中 $n_0 = 20$ 控制收缩强度，$\boldsymbol{\Sigma}_{\text{pool}}$ 为合并协方差（用 Ledoit–Wolf 估计）。样本越少，λ 越接近 1，协方差越向全局结构靠拢。

生成时从风格条件分布抽样，再逆变换回浓度空间：

$$\boldsymbol{z} \sim \mathcal{N}\left(\boldsymbol{\mu}_g, \boldsymbol{\Sigma}_g^{(\lambda)}\right), \qquad \tilde{x}_j = F_j^{-1}\left(\Phi(z_j)\right), \tag{5.6}$$

并对 $\tilde{x}_j$ 做非负截断。式(5.6) 即条件高斯 copula：它保留每个化合物的边际分布与风格内的相关结构，同时把风格信息压缩为均值与协方差两个量。与风格均值基线相比，收缩协方差在小样本风格上更稳定；与 CVAE 相比，它没有神经网络的训练方差，在本题的数据规模下更可靠。

5.3.3 最终方法：风格感知的缺陷约束

生成模型只保证“像这个风格”，不保证“缺陷不超标”。记缺陷化合物集合为 $\mathcal{J}$，其严格阈值为 τ_j，风格 g 中化合物 j 的 75% 分位数为 $q_{g,j}$，定义风格感知上限

$$\bar{c}_{g,j} = \max\left(\tau_j,\ q_{g,j}\right), \qquad \tilde{x}_j \leftarrow \min\left(\tilde{x}_j,\ \bar{c}_{g,j}\right) \quad (j \in \mathcal{J}). \tag{5.7}$$

这里取“阈值”与“风格分位数”的较大者，是为了同时避免两种错误：若只用 τ_j，Tripel 这类风格本身的 DMS 与双乙酰水平就高于通用阈值，一压会把风格特征抹平；若只用 $q_{g,j}$，则会放任某些样本显著超出安全水平。取上限后，生成结果既不破坏风格基线，也不产生风格正常波动之外的极端值。

有两处需要单独说明。其一，4VG 的风格上限不用式(5.7)，而取固定值 0.10 mg/L：小麦风格的 4VG 分位数显著高于非小麦风格的安全值，若按风格分位数设上限，等于承认小麦风格的酚味可以无限接近其自身分位水平。其二，stale hops 不是单一化合物，本文用反式-2-壬烯醛、DMS、ethyl 2-methylbutyrate、ethyl isovalerate 与 4VG 五列的标准化均值构造代理，并在迁移中对每一列单独施加“不高于源样本”的约束。各缺陷的阈值与依据见表 5.1。

表 5.1　缺陷化合物的严格阈值与取值依据

缺陷	对应列	严格阈值	单位	依据
DMS	`DMS`	17.25	μg/L	附件阈值与文献综合
Diacetyl	`X2.3.butanedione`	0.09	mg/L	附件阈值与文献综合
4VG	`X4VG`	0.10	mg/L	非小麦风格安全值
trans-2-nonenal	`X.E..2.nonenal`	0.10	μg/L	文献常用阈值
stale hops	五列复合代理	—	—	非单一化合物，见正文

反式-2-壬烯醛的单位问题在第 2 章已说明：附件标注为 mg/L，但数值范围与文献常用的 μg/L 阈值同一量级，本文按 μg/L 解释；若按标注单位，全部样本都远低于检出限，该维度将失去区分度。

5.4　跨风格迁移：最优传输与边际校准

设源风格为 g、目标风格为 g'。在正态分数空间中，均值与协方差匹配意义下的高斯最优传输映射[12] 为闭式：

$$T_{g\to g'}(\boldsymbol{z}) = \boldsymbol{\mu}_{g'} + \boldsymbol{\Sigma}_{g'}^{1/2}\boldsymbol{\Sigma}_{g}^{-1/2}\left(\boldsymbol{z} - \boldsymbol{\mu}_{g}\right), \tag{5.8}$$

其中矩阵平方根用对称半正定分解计算。式(5.8) 把源样本映射到目标风格，再逆变换回浓度空间。与“只加风格均值差”相比，它多了协方差校正，能同时改变化合物的相关结构。

仿射映射只匹配均值与协方差，不保证各化合物的边际形状，对零膨胀的痕量化合物尤其明显。因此迁移后对每一列再做一次秩映射，把生成样本的分位数对齐到目标风格的经验分布：

$$\tilde{x}_{i,j} \leftarrow Q_{g',j}\left(\frac{\operatorname{rank}(\tilde{x}_{i,j}) - 1/2}{n}\right), \tag{5.9}$$

其中 $Q_{g',j}$ 为目标风格化合物 j 的经验分位数函数。该步之后每一列的边际与目标风格严格一致，因此后文的 MMD 与覆盖度衡量的是化合物之间的相关结构，而非整体分布形状——引用这两个数值时必须带上这一口径。

按缺陷处理方式，迁移分三个变体：raw 只做式(5.8) 与式(5.9)，不加任何缺陷约束；strict 把缺陷列投影到严格阈值 τ_j；style 投影到式(5.7) 的风格上限。三者共用同一映射，差别只在投影，因此可以直接比较“安全”与“风格真实”两种取向的代价。

5.5 实验设置

生成模型的输入取 `8.xlsx` 校准后的 70 个化合物线性浓度，做 log1p 与逐列标准化。协方差用 Ledoit–Wolf 估计，收缩强度 $n_0 = 20$；每个风格每种模型生成 300 条样本；感官代理用 PLS，做嵌套 5 折交叉验证，平均 $R^2 = 0.220$。

风格分层划分训练与测试集，保证每个风格在测试集中至少有一个样本；小样本风格采用式(5.5) 的收缩估计，并在结果中单独标注其不确定性。对照模型为：风格均值加噪声（mean-noise）、全局协方差加风格均值平移（global-cov）、条件高斯 copula、copula 加缺陷约束（style cap），以及 OT 迁移。所有模型共用同一划分与随机种子 42。

5.6 结果与分析

三风格平均的五维评价见表 5.2。OT 加约束在分布保真（MMD 0.038）、覆盖度（0.863）与风格命中率（0.981）三项上都最好；条件 copula 的风格命中率接近（0.974），但 MMD 为 0.111、感官 RMSE 为 0.132，说明它更贴近风格中心却牺牲了分布与感官一致性；均值加噪声的命中率只有 0.851、覆盖度 0.300，是典型的模式崩塌——生成样本挤在风格均值附近，多样性几乎消失。

表 5.2　生成模型的五维评价（Tripel、Kriek、Lambic 三风格平均）

指标	均值加噪声	全局协方差	条件 copula	OT 加约束
分布保真：MMD^2	0.063	0.066	0.111	**0.038**
风格保真：随机森林命中率	0.851	0.667	0.974	**0.981**
多样性：覆盖度	0.300	0.233	0.430	**0.863**
缺陷控制：超严格阈值率	0.61/0.67/0.40	0.57/0.60/0.43	0.56/0.73/0.07	0.59/0.81/0.00
感官一致：画像 RMSE	0.090	0.095	0.132	**0.090**

缺陷一栏需要分开读。OT 加约束把反式-2-壬烯醛的超严格阈值率压到 0，但 DMS 与双乙酰仍有 0.59 与 0.81，原因不是约束失效，而是 Tripel、Kriek、Lambic 三个风格的 75% 分位数本身就高于附件给出的严格阈值（Tripel 的 DMS $q_{75} = 55.0$ μg/L、双乙酰 $q_{75} = 0.589$ mg/L，均高于 17.25 与 0.09 的阈值）。相对风格上限 $\bar{c}_{g,j}$ 的超阈值率在四类缺陷上均为 0.000。因此“风格允许”与“绝对安全”是两套口径，本文同时报告：前者说明生成结果没有超出该风格自身的正常波动，后者说明它在绝对意义上是否超标。把前者误写成后者，是这类生成任务最容易出现的夸大。

4VG 在所有风格与所有方案下都远低于其上限，在本数据中缺乏区分度，这一点在解释结果时需要注明，否则读者会以为该列没有参与约束。

迁移结果方面，源风格 Pils/Lager 的 Tripel 命中率为 0.00，经 OT 迁移后三个变体（raw、strict、style）的 Tripel 命中率均为 0.91，与 Tripel 画像的 Pearson 相关分别为 0.974、0.856 与 0.972，说明风格方向迁移成功。

三个变体的差别体现在缺陷列上。raw 把 DMS、双乙酰、反式-2-壬烯醛从源样本的 15.8 μg/L、0.117 mg/L、0.004 μg/L 抬到 41.8、0.418、0.115，11 个源样本全部恶化；strict 把它们压到 13.7、0.047、0.004，超严格阈值率为 0，且相对源样本的恶化比例为 0；style 保留 Tripel 的风格基线（39.8、0.398、0.099），相对风格上限的超标率为 0，但相对 Pils/Lager 的升高是风格本身应有的变化，不应读作缺陷恶化。前者对应“安全优先”，后者对应“风格优先”，两种取向的选择取决于用途：配方筛选可用 style，成品放行必须用 strict。

关键化合物的迁移幅度符合化学预期。乙醇由 5.19% 升至 8.79%，甘油由 1.64 升至 3.11 g/L，乙酸乙酯由 10.8 升至 40.3 mg/L，乙酸异戊酯由 1.15 升至 4.62 mg/L，异戊醇由 27.9 升至 54.6 mg/L——酯类与高级醇温和上升，与 Tripel 高酯、高酒精度、较厚酒体的风格特征一致。酒花萜类升幅最大，里那醇由 0.062 升至 1.14 mg/L，约为 Tripel 中位数 0.372 mg/L 的 3 倍，却只达其均值 2.97 mg/L 的 38%。同一结果在中位数口径与均值口径下评价相反，说明点估计在长尾化合物上难以同时满足两种口径，后续应以分位数约束取代均值匹配，而不是继续调 OT 的均值映射。

风格画像的案例结果为：Tripel、Kriek、Lambic 的生成画像与真实风格中位数的 Pearson 相关分别为 0.968、0.957、0.990，RMSE 为 0.051、0.147、0.071。Kriek 的误差最大，反映其真实感官分布本身更分散，单一的风格中心不足以概括。

5.7 讨论

生成模型的评价没有统一真值，本文用五维指标加案例，但仍有三点限制。

第一，风格分类器本身是在真实数据上训练的。若真实标签存在噪声，生成样本的“保真”分数会继承这种噪声，因此本文同时报告马氏距离与感官一致性，避免只依赖分类器。

第二，缺陷阈值来自 `8.xlsx` 与文献，不同风格、不同市场的阈值并不相同。本文把阈值作为可配置参数，并在敏感性分析中变动阈值，检查结论是否稳健；但“某个浓度是否算缺陷”这一问题最终仍需工艺与标准来判断，不是数据能单独回答的。

第三，式(5.8) 假设正态分数空间中的风格差异可由均值与协方差线性刻画。若风格流形高度非线性，线性映射只能迁移部分特征。改用核最优传输或条件流模型可以缓解，但必须同时保留缺陷约束与逐化合物的可解释性检查，否则会把“像”与“安全”

两个目标混在一起。

此外还有两处口径需要在结论前交代。其一，stale hops 的代理列里包含 ethyl 2-methylbutyrate 与 ethyl isovalerate 两个果香酯类，把它们纳入“不恶化”约束会同时抑制 Tripel 应有的酯类上升，因此 strict 迁移对这两列是保守偏置，不能读作对 stale hops 的独立实测。其二，部分风格样本过少（`Faro` 仅 3 个），生成模型在这些风格上的多样性指标既可能被高估也可能被低估，本文不把少数风格的结果外推到所有商业啤酒，而把它们作为“在本数据条件下可行”的方案，并建议补充同风格样本后复评。

6 结论与建议

6.1 主要结论

本文完成了数据对齐、分级评分、关键化合物识别与风格条件生成四段工作，三问共用一套数据底座与符号体系，结论如下。

6.1.1 问题一

在缺少原始 0–6 评分的条件下，“连续潜变量回归加有序校准”两层建模是可行的：折外等权融合在 5 折 $\times$ 3 次重复下取得宏平均 $R^2 = 0.227$、Spearman 0.432，保序校准后 QWK 为 0.376。逐维结果呈现清晰的化学梯度——酸度（0.690）、酒精度（0.678）、苦味（0.604）最强，barnyard（-0.039）等阈值型缺陷维度接近 0 甚至为负，说明“有明确化学载体且近似单调”的维度可预测，而“超过阈值才被感知且风格内变异小”的维度不可预测。

改进的边际收益需要如实看待。等权融合相对最强单体（极端随机树 0.223）只高 0.004，二者折间误差棒重叠；融合的实际价值在于折间方差更小与逐目标更均衡，而非宏平均上的显著提升。风格先验在岭回归上带来 $+0.024$，在融合模型上只带来 $+0.012$，因为树模型已能从化合物谱间接识别风格。

缺失稳健性在本文的遮蔽机制下可以接受：随机遮蔽 30% 化合物时 R^2 相对下降 19.3%、RMSE 相对上升 3.8%，非随机缺失（平均 24.8%）下降 10.9%，与 20% 随机缺失的 11.5% 接近。保序校准把 0 级预测比例由 min-max 的 7.6% 提到 11.3%，缓解了“向中间档压缩”，但仍远低于参考分级的 23.3%，尾部依旧被低估。

6.1.2 问题二

共表达图的结构与已知化学家族基本对齐：$K = 10$ 的近邻图给出 231 个节点、1 683 条边、8 个社区，模块度 0.586，酒花萜类（C2、C8）、酵母酯类与醇类（C4、C6）、麦芽来源的醛与呋喃（C5）各自成模块。但社区并不严格等于化学家族，同一模块内常混有酯、萜与醇，因为它们受同一发酵条件驱动，所以社区只能作为“哪些化合物应一起考虑”的先验。

稳定性必须按条目而非按整组报告。500 次 bootstrap 下平均入选频率 0.525、方法间 Jaccard 平均 0.313；没有任何一个感官维度的三个条目全部达到 0.8，而 24 个维度至少两个条目达到 0.5。一个只给三个名字、不带频率的 Top-3 会掩盖它对重采样的敏感程度。

最重要的发现是统计显著与化学相关在本数据上出现了分离。双乙酰、DMS 与反式-2-壬烯醛的纯数据融合名次分别为 120.8、86.5、91.4，选中的是蛋白、色度、总硫等风格或物化代理；只有在叠加文献先验（$\lambda = 0.5$）后，三个直接化合物才回到 Top-3，而代价是名单与纯数据重合率降到 0.387、平均稳定性降到 0.303。这说明在本数据中，缺陷直接化合物的边际信号弱于其风格混杂，相关排序不能直接当作因果结论。

6.1.3 问题三

条件高斯 copula 加高斯最优传输的路线在本题的数据规模下是有效的。三风格平均 MMD 为 0.038、覆盖度 0.863、风格命中率 0.981，均优于均值加噪声（0.063/0.300/0.851）、全局协方差（0.066/0.233/0.667）与纯 copula（0.111/0.430/0.974）。后者的命中率高但 MMD 与感官 RMSE 更差，说明它更贴近风格中心却牺牲了分布形状——这正是“单一指标会误导”的例证。

跨风格迁移成功且可定向。Pils/Lager 的 Tripel 命中率为 0.00，迁移后三个变体均为 0.91，与 Tripel 画像的 Pearson 相关为 0.974（raw）、0.856（strict）、0.972（style）。关键化合物的迁移幅度与化学预期一致：乙醇 5.19% 升至 8.79%，乙酸乙酯 10.8 升至 40.3 mg/L，里那醇 0.062 升至 1.14 mg/L。

缺陷控制必须区分两套口径。相对严格阈值，DMS 与双乙酰的超阈值率仍为 0.59 与 0.81，因为 Tripel、Kriek、Lambic 三个风格的 75% 分位数本身就高于附件给出的通用阈值；相对“风格上限 $\max(\tau_j, q_{g,j})$”，四类缺陷的超阈值率均为 0。前一口径偏保守，后一口径更符合风格真实性，二者不可互相替代：成品放行应按严格阈值，配方筛选可用风格上限。

6.2 对酿造实践的建议

第一，把化合物—感官模型作为配方与工艺调整的辅助工具，而不是人工品评的替代品。模型能快速筛出可能影响目标风味的化合物并给出相对等级，但绝对档位依赖校准假设，最终判断仍需品评小组与生产条件。

第二，对关键化合物建立分风格的监控窗口。问题二给出的 Top-3 可作为优先监测项，但应与问题一的维度权重、问题三的缺陷上限结合使用，避免只盯少数化合物而忽略整体风味平衡。

第三，缺陷控制应前置到原料与发酵过程。DMS 来自麦芽的 SMM 与 DMSO 热分解，双乙酰来自 α-乙酰乳酸的氧化脱羧，4VG 来自阿魏酸脱羧，反式-2-壬烯醛来自亚油酸氧化——这些环节都在灌装之前。生成模型的阈值约束只能用于配方筛选，不能替代工艺控制。

第四，数据积累应优先补齐“原始 0–6 评分”与“缺失原因”。本文的校准层是对缺失标签的补救，不是替代；若能拿到原始评分卡与检测限信息，问题一的绝对等级精度与问题三的感官评价都会明显改善。

6.3 局限与展望

本文的局限有四方面。**其一**，问题一缺少真实 0–6 标签，分级结果的绝对水平依赖校准锚点，QWK 衡量的是同一连续信号在两种离散化下的一致性，不等于与人工评分逐档吻合。**其二**，问题二的关联基于观测数据，相关不等于因果，共表达图上的模块可能混合了共同调控、批次效应与测量误差。**其三**，问题三的生成质量缺少统一真值，五维指标与案例只能提供相对比较，不能证明生成样本在真实酿造中可行；感官代理模型的嵌套交叉验证平均 R^2 只有 0.220，缺陷维度的预测尤其弱。**其四**，外部数据只能整合到 22 个风格层级，与附件没有共同酒名、酒厂或条码，无法逐酒连接，只能用于风格级原型与效度校验。

后续工作可从三个方向展开。一是引入原始感官评分与检测限数据，把分级校准从“分位数锚定”升级为“有序标签监督”。二是用干预实验或代谢网络先验替代纯相关图，提升问题二因果解释的可信度。三是把问题三的生成模型与工艺参数连接，形成“工艺—化合物—感官”的闭环优化，而不是只在化合物层面做条件生成。

参考文献

[1] 刘倩，贾建华，白艳龙，等，啤酒风味物质及分析技术研究进展，中国酿造，42(8)：20-27，2023。

[2] 李俊杰，刘智颖，赵丽娜，等，基于固相微萃取结合气相色谱-质谱联用技术分析苦荞啤酒中关键香气物质，中国酿造，44(7)：139-147，2025。

[3] Vanderhaegen B, Neven H, Verachtert H, et al., The chemistry of beer aging: a critical review, Food Chemistry, 95(3): 357-381, 2006.

[4] Little R J A, Rubin D B, Statistical Analysis with Missing Data, 3rd ed. Hoboken: Wiley, 2019.

[5] Polozoff S, Top Beer Information, `https://www.kaggle.com/datasets/stephenpolozoff/top-beer-information`, 2026-10-24.

[6] Cohen J, Weighted kappa: nominal scale agreement with provision for scaled disagreement or partial credit, Psychological Bulletin, 70(4): 213-220, 1968.

[7] Hastie T, Tibshirani R, Friedman J, The Elements of Statistical Learning, 2nd ed. New York: Springer, 2009.

[8] Wold S, Sjöström M, Eriksson L, PLS-regression: a basic tool of chemometrics, Chemometrics and Intelligent Laboratory Systems, 58(2): 109-130, 2001.

[9] Efron B, Bootstrap methods: another look at the jackknife, The Annals of Statistics, 7(1): 1-26, 1979.

[10] Langfelder P, Horvath S, WGCNA: an R package for weighted correlation network analysis, BMC Bioinformatics, 9: 559, 2008.

[11] Lundberg S M, Lee S I, A unified approach to interpreting model predictions, Advances in Neural Information Processing Systems, 30: 4765-4774, 2017.

[12] Peyré G, Cuturi M, Computational optimal transport, Foundations and Trends in Machine Learning, 11(5-6): 355-607, 2019.